

Présentations IA et leurs modèles

Sommaire

- Introduction
- Vocabulaire
- **Présentation IA:**
 - Open Ai Deepseek
 - Google Alibaba
 - Anthropic Mistral
 - Meta
- **Présentation model:**
 - Open Ai Deepseek
 - Google Alibaba
 - Anthropic Mistral
 - Meta
- Comparaison d'image
- Comparaison benchmark



Vocabulaire

Model: système entraîné à faire des prédictions ou générer du contenu à partir de données.

Prompt : texte donné au modèle pour générer une réponse.

Token: unité de texte traitée par un modèle, souvent un mot ou un morceau de mot.

Api: interface qui permet d'interagir avec un modèle IA via du code

Mixture of Experts (MoE): permet à une IA d'activer seulement les experts nécessaires, ce qui la rend plus rapide, spécialisée et économique.



IA

Présentation des IA américaine, chinoise et française

OpenAI

US

- la plus utilisée
- model fermé
- **Avantages** : polyvalent, simple, Mise à jour régulière, multilingue
- **Inconvénients** : payant, pas exécutable en local, donnée stocker
- **Offre** : gratuite, pro, entreprise, api



Google



- Très performante
- **Models** : fermé (gémini) et open source(gemma)
- **Intégration** dans l'environnement Google
- **Avantages** : Bien intégré à Google, Multimodal, Modèle puissant(gemini1.5)
- **Inconvénients** : Un compte Google, Encore en amélioration, Modèle fermé
- **Offre** : gratuit, pro, api, local (gemma)

Anthropic


A\ ANTHROPIC



- plus orienter code pour certain model
- model fermé
- **Avantages** : Très bon en compréhension fine, Conserve bien le contexte
- **Inconvénients** : Moins performant en français, Version la plus puissante payante
- **Offre** : gratuit, pro, entreprise

Meta

- Model open source
- **Avantages** : Gratuit à utiliser,
Exécutable en local
- **Inconvénients** : Pas d'interface
simple, condition d'accès
- **Offre** : Api, local, gratuit



Deepseek

Chinois

- orienté codes.
- Pas très utilisé en Occident
- **Avantages** : Spécialisée en codage, "Gratuit (dans certaines limites)"
- **Inconvénients** : Encore en développement, Très orienté "code"
- **Offre** : gratuite, pro, entreprise, api



Alibaba

- **Alibaba cloud** : puissance de calcul (serveurs, stockage, bases de données)
- **Qwen** : modèles d'IA créés par Alibaba Cloud (qwen-3)
- **Avantages** : Multilingue, Modèles open source, Version spécialisée pour le code
- **Inconvénients** : Moins performant en français, Conditions d'accès
- **Offre** : local, gratuit, api



Français


- Orienté texte + logique.
- **Avantages** : open source, très performante pour sa taille
- **Inconvénients** : pas d'outil intégrer, pas encore multilingue(Français et anglais)
- **Offre** : Gratuit, local, entreprise, pro, etudiant






Models


OpenAI




GPT-4o (o4)



o3



GPT-3.5



Autre

Model utilisé de **base**
par le site (**limite**).

Force:



Rapide



Multimodal (texte, image,
voix)



Performances améliorées à
coût réduit

Meilleur modèle en
raisonnement pur.

Force:



Raisonnement complexe
amélioré



Chaînes de pensée privée
intégrées



Performance optimisée

Model par **défaut**.

Force:



Réponses rapides et fluides



Bonne compréhension du
langage naturel



Moins gourmand en
ressources


Sora

↳ génération vidéo réaliste


Dall E

↳ génération d'image


Google




Anthropic



Meta



Deepseek



DeepSeek V3

Modèle **généraliste**, rapide mais faible en raisonnement, Architecture **Mixture of Experts**

Force:




Très bon en langage naturel



Excellente performance en raisonnement



Open-source et gratuit à utiliser



DeepSeek R1

Spécialisé en **résolution de problèmes complexes & logique**, considéré comme l'un des **meilleurs** modèles **open source** en raisonnement

Force:



Très fort en programmation



Résout bien les problèmes de type LeetCode / ingénierie



Accès libre et open-source




Autre


MoE

↳ Pensés pour les experts / chercheurs

Alibaba



Qwen 3



Qwen 2.5 VL



Autre

Modèle **open source** avancé,
Architecture **Mixture of Experts**

Force:



Très bon en langage naturel



Performant en raisonnement
logique



Open-source et adapté aux
usages pro

Modèle *multimodal* : il comprend **le texte et les images**.

Force:



Lit et décrit les images avec
précision



Combine image + texte pour
répondre à des questions
complexes




Utile pour OCR, analyse de
documents, inférences
visuelles


MoE

↳ Pensés pour les experts /
chercheurs


Mistral



Mistral small



Mistral medium



Mistral large



Autre

Léger, adapté aux systèmes avec moins de ressources

Force:



Très rapide et léger



Bonne qualité de génération pour sa taille



Open-source et facile à fine-tuner

Compromis entre performance et rapidité

Force:



MoE → plus rapide et efficace



Comparable à GPT-3.5 sur de nombreuses tâches



Bon rapport qualité / coût en production

Adapter à des tâches **complexes** et **contexte long**

Force:



Niveau GPT-4-turbo



Très bon en raisonnement et codage



Disponible via API à prix compétitif

Pixtral Large

↳ Génération d'images haute qualité

DevStral Small

↳ Modèle récent, optimisé pour le développement



Comparaison

Génération d'image

Prompte:

Un chevalier médiéval en armure pleine de brillance debout sur une colline herbeuse au lever du soleil, surplombant une vaste vallée remplie de brouillard. Le chevalier tient une épée détaillée avec des gravures, et sa cape flotte dans le vent. En arrière-plan, un château de pierre en ruine peut être vu sur une montagne lointaine. La scène est cinématographique, avec un éclairage doré chaud, des détails élevés, des textures réalistes et une composition équilibrée.



OpenAI

Model:
DALLE-3



Google

Model:
Imagen



Mistral


Model:
pixtral




Comparaison

Benchmark


MMLU-Pro (Reasoning & Knowledge)




Humanity's Last Exam (Reasoning & Knowledge)




HumanEval (Coding)




SciCode (Coding)




LiveCodeBench (Coding)



AIME 2024 (Competition Math)



MATH-500 (Quantitative Reasoning)



MODEL ↕	CREATOR ↕	CONTEXT WINDOW ↕	ARTIFICIAL ANALYSIS INTELLIGENCE INDEX ↕	BLENDED ↕ USD/1M Tokens	MEDIAN ↕ Tokens/s	MEDIAN ↕ First Chunk (s)
o3	 OpenAI	128k	70	\$17.50	166.3	15.82
o4-mini (high)	 OpenAI	200k	70	\$1.93	125.6	37.40
Gemini 2.5 Pro		1m	69	\$3.44	152.0	36.26
DeepSeek R1 0528 (May '25)		128k	68	\$0.96	25.1	3.71
Gemini 2.5 Pro (May' 25)		1m	68	\$3.44	154.6	36.94
Grok 3 mini Reasoning (high)		1m	67	\$0.35	137.6	0.30
o3-mini (high)	 OpenAI	200k	66	\$1.93	181.3	44.47
Gemini 2.5 Flash (Reasoning)		1m	65	\$0.99	338.5	14.70
Claude 4 Opus Thinking	ANTHROPIC	200k	64	\$30.00	57.2	2.60
o3-mini	 OpenAI	200k	63	\$1.93	180.7	14.44
Qwen3 235B (Reasoning)		128k	62	\$2.63	70.0	1.14
o1	 OpenAI	200k	62	\$26.25	179.7	15.14
Llama Nemotron Ultra Reasoning		128k	61	\$0.90	41.5	0.66
Claude 4 Sonnet Thinking	ANTHROPIC	200k	61	\$6.00	70.8	1.48
Gemini 2.5 Flash (April '25) (Reasoning)		1m	60	\$0.99	367.7	8.43
DeepSeek R1 (Jan '25)		128k	60	\$2.36		

Source: <https://artificialanalysis.ai/leaderboards/models>

Thank you. Merci. 謝謝. dhanya

Axel Rosa
Stagiaire

Yanis Seghier
Stagiaire